

# Erkennung epileptische Anfälle mittels Künstlicher Intelligenz: Drei Modelle im Vergleich

Ayman Kabawa, Quynh Anh Nguyen, Jana Taube  
Technische Universität Darmstadt, Darmstadt, Germany

ayman.ka96@gmail.com, quynhanhnguyen310398@gmail.com, jana.taube@stud.tu-darmstadt.de

**Zusammenfassung**—Dieser Bericht vergleicht drei Methoden zur Erkennung von epileptischen Anfällen und deren zeitlichem Beginn (Onset) in EEG-Daten mit Hilfe von künstlicher Intelligenz. Dabei werden sowohl Zeitbereichsdaten als auch Zeit-Frequenzbereichsdaten der Wavelet-Transformation mit Feature Extraction verwendet. Zur Klassifikation werden ein Artificial Neuronal Network (ANN), ein Convolutional Neuronal Network (CNN) und eine Support Vector Machine (SVM) verwendet. Die Ergebnisse der Zeitbereichsdaten mit dem CNN (Time-CNN), der Wavelet-basierten Daten mit dem ANN (Wavelet-ANN) und der Wavelet-basierten Daten mit der SVM (Wavelet-SVM) werden miteinander verglichen. Die Analyse zeigt, dass das Time-CNN mit einem F1-Score von 0,6 am besten abschneidet, gefolgt von Wavelet-ANN mit einem F1-Score von 0,59. Die Wavelet-SVM schneidet mit einem F1-Score von 0,48 am schlechtesten ab.

## I. EINLEITUNG

Epilepsie betrifft über 50 Millionen Menschen weltweit und verursacht Anfälle mit Symptomen wie Bewusstseinsverlust und Muskelkrämpfen [1]. Eine präzise Diagnose und Behandlung sind entscheidend um Anfälle zu verhindern und die Lebensqualität zu verbessern [2]. Typischerweise werden Elektroenzephalogramm (EEG) Daten für die Diagnose verwendet. Derzeit wird das EEG manuell ausgewertet, was zeitaufwändig ist und dazu führen kann, dass Anfälle übersehen werden. Eine automatisierte Detektion durch künstliche Intelligenz könnte helfen, medizinisches Personal zu entlasten und Anfälle effektiver zu erfassen.

## II. HINTERGRUND

In vorherigen Arbeiten wurden zur automatischen Anfallserkennung unterschiedliche Signalbereiche wie der Zeitbereich, der Frequenzbereich und der Zeit-Frequenz-Bereich verwendet [3]. Die EEG-Daten liegen zunächst im Zeitbereich vor. Jedoch ermöglicht eine Darstellung im Frequenzbereich eine präzisere Signalanalyse [3]. Die Fourier-Transformation, eine gängige Methode zur Umwandlung in den Frequenzbereich, geht allerdings mit einem Verlust an zeitlicher Information einher. Die Wavelet-Transformation bietet eine optimale Kombination aus Zeit- und Frequenzbereich für die Analyse von epileptischen Anfällen, da sie Informationen aus dem Frequenzbereich extrahiert, ohne die zeitliche Struktur des Signals zu beeinträchtigen [4].

Liu et al. [5], Omidvar et al. [6] und Akut et al. [7] schlagen alle die Anwendung der Wavelet-Zerlegung zur Detektion von epileptischen Anfällen vor, verwenden jedoch

mit einer Support Vector Machine (SVM), einem Artificial Neuronal Network (ANN) und einem Convolutional Neuronal Network (CNN) unterschiedliche Klassifikatoren. Die ersten beiden Ansätze (Liu et al. und Omidvar et al.) konzentrieren sich auf die Extraktion statistischer Merkmale (Features) aus den Subbändern. Um die Effizienz und Genauigkeit des Modells zu steigern, führt Omidvar et al. [6] Featureauswahl durch, während Liu et al. [5] Nachverarbeitungstechniken betonen. Akut et al. [7] nutzt hingegen die Fähigkeit der Mustererkennung eines CNNs aus, um den aufwändigen Featureextraktionsprozess zu vermeiden. Alle drei Ansätze zeigen eine hohe Genauigkeit, Sensitivität und Spezifität von jeweils über 95% bei gleichzeitiger Robustheit. Es ist jedoch zu beachten, dass ihre Bewertungen auf kleinen Datensätzen mit kurzen EEG-Signalen und minimalen Artefakten durchgeführt wird. Die Frage, wie sich diese Modelle bei großen Datensätzen verhalten, bleibt offen und bedarf weiterer Untersuchungen. Außerdem ist zu beachten, dass sich diese Studien im Wesentlichen nur auf die Anfallserkennung beziehen und die Bestimmung des Anfallsbeginns nicht berücksichtigen.

Das Ziel dieses Berichts ist die korrekte Detektion von epileptischen Anfällen und ihrem zeitlichen Beginn (Onset). Hierfür werden zwei Methoden auf Basis der Diskreten Wavelet-Transformation (DWT) und eine Methode im Zeitbereich verglichen. Für den Zeitbereich ist lediglich minimale Vorverarbeitung in Form von Filterung und Segmentierung erforderlich. Für die Wavelet-basierten Daten werden die Zeitsignale nach erster Vorverarbeitung mit einer Level 5 Daubechies 4 (db4) Funktion Wavelet-transformiert. Damit wird eine Zerlegung in sechs Frequenzbänder erreicht, aus denen jeweils sechs statistische Features extrahiert werden. Für eine Klassifikation zwischen Anfall und Anfall frei werden drei Modelle mit den vorverarbeiteten Daten trainiert: ein CNN, ein ANN und eine SVM. Das CNN wird mit den Zeitbereichsdaten (Time-CNN) trainiert, während das ANN und die SVM mit den Wavelet-basierten Daten (Wavelet-ANN und Wavelet-SVM) trainiert werden. Abschließend wird ein Nachverarbeitungs-Schema implementiert, um die Klassifikationsergebnisse zu verfeinern, zu stabilisieren und den Onset zu bestimmen. Ein Flowchart der drei Methoden ist in Abbildung A.1 im Anhang zu finden.




Abbildung 1: Fp1-F3, Fp2-F4 und C3-P3 Montagen einer Session unterteilt in (nicht überlappende) 5-Sekunden Segmente

### III. MATERIAL UND METHODIK

#### A. EEG Datensatz

Der EEG-Datensatz, bereitgestellt durch das KISMED Institut der Technische Universität Darmstadt, umfasst mehr als 6000 verschiedene Aufnahmen, die über 19 Kanäle mit variabler Dauer und Abtastfrequenz aufgezeichnet wurden. Es gibt mehrere Sessions pro Patient, wobei pro Session maximal ein epileptischer Anfall auftritt. Leider liegen keine genaueren Informationen zu den Aufnahmebedingungen vor.

Aufgrund des begrenzten Arbeitsspeichers wird ein spezifischer Algorithmus entwickelt, um den Datensatz in Untermengen zu gliedern, die dann in Trainings-, Test- und Validierungssätze (80%, 10%, 10%) unterteilt werden. Um Datenleaks zu vermeiden bleiben die Sessions eines Patienten innerhalb derselben Untermenge. Sessions mit Anfall werden gleichmäßig über die drei Sätze innerhalb jeder Untermenge verteilt. Wenn dies nicht möglich ist, werden dem Trainingssatz die meisten Anfälle zugewiesen, um ein optimales Training zu gewährleisten. Diese systematische Unterteilung gewährleistet die Integrität der Daten sowie eine optimale Grundlage für eine effiziente Analyse und Modellentwicklung.

#### B. Vorverarbeitung

Die rohen EEG-Daten werden zunächst mit einem 50-Hz-Notch-Filter und einem Bandpassfilter im Bereich von 0,5 bis 70 Hz gefiltert, um den Einfluss der europäischen elektrischen Netzfrequenz, Gleichanteile und Rauschen mit hohen Frequenzen zu entfernen. Anschließend erfolgt eine Abtastratenkonvertierung (Resampling) des Signals, um eine einheitliche Abtastfrequenz von 173,61 Hz zu erhalten und die gewünschten Frequenzbänder für die folgende Wavelet-Dekomposition zu erreichen. Für jede Session werden aus den 19 Kanälen die drei bipolaren Montagen Fp1F3, Fp2-F4 und C3P3 berechnet. Anschließend wird jede Session in 5 Sekunden lange, nicht überlappende Segmente unterteilt (Abbildung 1). Die Vorverarbeitung der Zeitbereichsdaten ist damit abgeschlossen.

#### C. Wavelet-Transformation und Featureextraktion

Die Wavelet-Transformation implementiert eine Faltung des Zeitsignals mit einer Wavelet-Funktion, deren Wahl je nach Kontext variieren kann. Bei der DWT erfolgt die Zerlegung des Zeitsignals in verschiedene Frequenzbändern, welche durch Wavelet-Koeffiziente repräsentiert werden. Dieser Prozess entspricht der Anwendung mehrerer Paare von Hoch- und

Tabelle I: Frequenzbereiche der Waveletkoeffizienten

Signalkomponent	Frequenzband in Hz
cA	0,5 - 2,7
cD5	2,7 - 5,4
cD4	5,4 - 10,9
cD3	10,9 - 21,7
cD2	21,7 - 43,4
cD1	43,4 - 86,8

Tiefpassfiltern auf das Signal, wodurch unterschiedliche Frequenzbereiche isoliert und somit eine präzise Frequenzanalyse ermöglicht wird [3, 4].

Auf Basis der Ergebnisse von [3] und [5] wird die db4-Funktion als Wavelet-Funktion mit einer Level 5 Dekomposition verwendet, um pro Segment jede der drei Montagen des vorverarbeiteten Zeitsignals in den Zeit-Frequenzbereich zu transformieren. Dadurch werden die sechs in Tabelle I dargestellten Koeffizienten mit zugehörigen Frequenzbändern gewonnen. Jeder Koeffizient entspricht einem Zeitsignal der Länge 5 Sekunden (Segmentlänge) bei dem nur die entsprechenden Frequenzen vertreten sind. Eine beispielhafte Zerlegung eines Signals ist im Anhang in Abbildung B.1 graphisch dargestellt.

Pro Segment ergeben sich 18 Koeffizienten (3 Montagen  $\times$  6 Koeffizienten). Für jeden Koeffizienten werden sechs statistische Features erfasst. Diese Features umfassen

- Energie: gibt die Stärke des Signals an [8]
- Entropie: gibt die numerische Maßzahl für die Unsicherheit eines Ergebnisses an [8]
- Mittelwert ( $\mu$ ): zeigt die Frequenzverteilung [9]
- Standardabweichung (STD): gibt an, wie stark die Daten vom Mittelwert streuen [9]
- Nulldurchgangsrate (ZCR): gibt die Fluktuation der Daten an [9]
- Mean Absolute Value (MAV): ist ein Maß für die Frequenzinformation des Signals [10]

Die genauen Formeln zur Berechnung sind in Anhang C dargestellt. Insgesamt ergeben sich 108 Features pro Segment (6 Features  $\times$  18 Koeffizienten)

#### D. Klassifikation

Für die Klassifikation der einzelnen Segmente werden ein ANN, ein CNN und eine SVM verwendet. Die zum Training verwendeten Segmente sind stark unausgeglich (6% mit Anfall, 94% ohne Anfall), was ein erhebliches Problem darstellt, da gängige Evaluierungsmetriken dazu neigen, Modelle auf die Bewertung der häufigsten Fälle auszurichten [11]. Um das vorzubeugen, wird Oversampling durchgeführt, wobei künstlich Daten zu dem Originaldatensatz hinzugefügt werden, um die Größe der Minderheitsklasse zu erhöhen. Anschließend werden alle Daten auf einen Bereich zwischen [0, 1] normalisiert um bessere Konvergenz, Stabilität, und schnelleres Training zu garantieren [12, 13]. Dieser Vorgang wird sowohl für die Zeitdaten als auch für die Features aus dem Zeit-Frequenzbereich durchgeführt.

Die Architekturen der drei verwendeten Klassifikatoren

werden im folgenden kurz beschrieben. Detaillierte Graphiken und genauere Informationen zum Training befinden sich in Anhang D.

1) *CNN Klassifikator mit Zeitdaten (Time-CNN)*: Das CNN (Abbildung D.1) besteht aus einer Eingangsschicht der Dimension (898, 3) für das Zeitsignal, gefolgt von zwei Convolutional Layers (Kernel: 3, Filter: 64) mit LeakyReLU-Aktivierungsfunktion um das Verschwinden von Gradienten zu verhindern. Nach einer Glättungsschicht folgen drei Hidden Layers mit 128, 64 und 32 Neuronen, ebenfalls mit LeakyReLU-Aktivierungsfunktion. Eine Dropout-Schicht mit einer Rate von 0,2 reduziert Overfitting, bevor das Signal die Ausgangsschicht mit Sigmoid Aktivierungsfunktion für die binäre Klassifikation erreicht.

2) *ANN Klassifikator mit Features aus Zeit-Frequenzbereich (Wavelet-ANN)*: Das ANN beginnt mit einer Eingangsschicht der Dimension 108, gefolgt von vier Hidden Layers mit jeweils 512, 256, 128 und 32 Neuronen (Abbildung D.2). Jede dieser Schichten verwendet die LeakyReLU-Aktivierungsfunktion und werden von einer Schicht mit Dropout-Rate von 0,2 abgeschlossen. In der Ausgangsschicht wird die Sigmoid Aktivierungsfunktion verwendet.

3) *SVM Klassifikator mit Features aus Zeit-Frequenzbereich (Wavelet-SVM)*: Bei der Klassifikation mit SVM (Abbildung D.3) werden drei separate SVM-Modelle trainiert, die jeweils für eine Montage klassifizieren. Alle drei Modelle verwenden einen RBF Kernel, einen hohen Strafterm ( $C=1000$ ), automatische Berechnung des Gamma-Werts und Shrinking für eine beschleunigte Berechnung.

#### E. Nachverarbeitung

Bei der Nachverarbeitung wird zwischen den Segmenten und der Sessions unterschieden. Die Modelle aus Abschnitt III-D klassifizieren nur die Segmente, während die Sessions anschließend ausgewertet und ein eventueller Onset bestimmt werden.

Die Ausgabe der SVM ist bereits eine binäre Klassifikation von '1' (Anfall) oder '0' (kein Anfall) pro Segment. Die Ausgaben des ANN und CNN erstrecken sich jedoch über das kontinuierliche Intervall zwischen 0 und 1. Daher ist ein Schema erforderlich, um auf die gewünschte binäre Klassifikation zu kommen. Als Schwellwert wird bei dem ANN der Median pro Session (adaptiver Median) und bei dem CNN der prozentuale adaptive Wert (90%) pro Session verwendet. Übersteigt der Wert eines Segments den Schwellwert, so wird das Segment mit '1' (Anfall), sonst '0' (kein Anfall) versehen.

Bei der Auswertung der Sessions wird für alle drei Modelle eine Art Mehrheitsentscheidung implementiert, welche in Abbildung 2 graphisch dargestellt ist. Sie basiert auf der Datensatzstruktur, die pro Session nur ein Anfallintervall zulässt. Ein Abschnitt wird als potenzieller Anfall betrachtet, wenn mindestens zwei aufeinanderfolgende Segmente mit 'Anfall'




Abbildung 2: Klassifikation der Sessions und Bestimmung des Onsets

Tabelle II: Ergebnisse Segmente

Methode	F1 Score	Accuracy	Precision	Recall
Wavelet-ANN	0,29	0,85	0,2	0,51
Wavelet-SVM	0,19	0,6	0,11	0,79
Time-CNN	0,11	0,59	0,06	0,44

klassifiziert sind. Der längste potenzielle Anfall wird als 'prognostizierter Anfall' identifiziert. Bei gleicher Länge wird der zeitlich erste als solcher bestimmt. Der Beginn eines Anfalls entspricht dem Start des ersten 'Anfall'-Segments.

#### F. Performance-Bewertung

Für die Bewertung der Modelle auf Segmentebeben werden die gängigen Metriken F1-Score, Accuracy, Precision und Recall [14], sowie die Receiver Operating Characteristic (ROC) mit der Area Under the Curve (AUC) verwendet. Bei der Beurteilung der Performance in den Sessions nutzen wir eine spezielle Metrik des KISMED Instituts der TU Darmstadt und andere Definitionen von richtig positiv (TP), falsch positiv (FP), richtig negativ (TN) und falsch negativ (FN), die die Latenz besonders berücksichtigt. Die Formeln dafür sind in Anhang E genauer dargestellt.

## IV. ERGEBNIS

Die drei Methoden Wavelet-ANN, Wavelet-SVM und Time-CNN werden zunächst auf Segmentebeben bewertet, bevor die Ergebnisse der Sessions und die Vorhersage des Anfallbeginns betrachtet werden.

Die Ergebnisse der Modelle bei den Segmenten ist in Tabelle II zusammengefasst. Bei der Accuracy ist zu beachten, dass sie aufgrund der starken Unausgewogenheit der Testdaten nicht unbedingt die tatsächliche Performance der Modelle widerspiegelt. Entscheidend für die Modellwahl ist demnach hier der F1-Score, wobei Wavelet-ANN mit 0,29 die beste Leistung erzielt, gefolgt von Wavelet-SVM mit 0,19 und Time-CNN mit 0,11. Die ROC-Kurve (Abbildung 3) ergibt ähnliche Ergebnisse, wobei Wavelet-ANN mit einem AUC-Wert von 0,78 am besten abschneidet. Die Unausgewogenheit des Datensatzes zeigt sich auch in den Werten für Precision (niedrig) und Recall (hoch).

Bei der Analyse der Sessions in Tabelle III ist ersichtlich, dass Time-CNN die beste Leistung mit einem F1-Score von 0,6 erzielt, gefolgt von Wavelet-ANN mit 0,59 und Wavelet-SVM mit 0,48. Auch bei den Ergebnissen der KISMED-Performancemetrik und der Latenz ist zu erkennen, dass Time-




Abbildung 3: ROC

Tabelle III: Ergebnisse Session

Methode	F1 Score	Accuracy	Precision	Recall
Wavelet-ANN	0,59	0,43	0,43	0,97
Wavelet-SVM	0,48	0,36	0,37	0,7
Time-CNN	0,6	0,44	0,43	0,99

Methode	Performance Metrik	Latenz
Wavelet-ANN	0,30	39
Wavelet-SVM	0,16	48
Time-CNN	0,33	36

CNN die überzeugendsten Ergebnisse mit einem Performancewert von 0,33 und einer Latenz von 36 erzielt. Wavelet-ANN erreicht mit einem Performancewert von 0,3 und einer Latenz von 39 ebenfalls akzeptable Ergebnisse, während Wavelet-SVM mit einem Performancewert von 0,16 und einer Latenz von 48 deutlich schlechter abschneidet.

## V. DISKUSSION UND AUSBLICK

Die vorgestellten Methoden zur Detektion epileptischer Anfälle in EEG-Daten überzeugen besonders durch ihre Fähigkeit zur Generalisierung. Alle drei Methoden erzielten bessere Ergebnisse bei der Analyse mit unabhängigen Daten als bei den für das Training verwendeten Daten. Es ist besonders wichtig zu betonen, dass eine gute Leistung der Modelle auf Segmentebene nicht automatisch zu einer guten Leistung in einer gesamten Session führt. Dies wird bei dem CNN deutlich. Das CNN hat in den Sessions die besten Ergebnisse erzielt, obwohl es bei den Segmenten den niedrigsten F1-Score erzielt hat. Um die genaue Ursache dafür zu ermitteln, bedarf es weiterer Untersuchungen im Bereich der Nachverarbeitung. Eine vielversprechende Möglichkeit könnte darin bestehen, ein zweites Neuronales Netz zur Klassifizierung einer gesamten Session zu trainieren. Dieses zusätzliche Netz könnte speziell darauf ausgelegt sein auf Basis der Segmentklassifikation, den Onset zu bestimmen. Des Weiteren ist zu erwähnen, dass epileptische Anfälle mit einer Dauer von weniger als 5 Sekunden aktuell aufgrund der Wahl der Nachverarbeitung (mindestens zwei aufeinander

folgenden Segmenten mit Anfall) nicht erkannt werden können.

Im Allgemeinen zeigen alle Modelle eine hohe Rate an FP und TP Ergebnissen, sowie eine niedrige Rate an TN Ergebnissen. Insbesondere im medizinischen Kontext sind FP Ergebnisse jedoch nicht so gravierend wie FN. In diesem Zusammenhang bedeutet dies, dass eine übermäßige Klassifizierung von Segmenten als epileptisch erfolgt. Das kann zwar zu unnötigen Alarmen führen, aber es gewährleistet, dass nur sehr wenige Anfälle unerkannt bleiben.

In zukünftigen Arbeiten könnte es lohnenswert sein, neben der Nachverarbeitung auch die Vorverarbeitung weiter zu verfeinern. Dabei könnten beispielsweise mehr Artefakte gezielt herausgefiltert werden, etwa mithilfe der wICA-Methode von [15]. Eine einfache und effektive Verbesserung der Bewertungsmetrik, insbesondere der Latenz, könnte durch die Verwendung überlappender Segmente erreicht werden. Eine Optimierung der Modelle könnte mittels Hyperparameter-Tuning oder Feature-Selektion, beispielsweise durch den Einsatz genetischer Algorithmen von [6], erfolgen. Es ist jedoch zu beachten, dass für diese Methoden ein großer Arbeitsspeicher und lange Rechenzeit benötigt werden.

## VI. ZUSAMMENFASSUNG

Dieser Bericht konzentriert sich auf die Evaluierung von drei verschiedenen Methoden zur Detektion epileptischer Anfälle in EEG-Daten: Wavelet-ANN, Wavelet-SVM und Time-CNN. Der Schwerpunkt liegt dabei auf der Bewertung sowohl auf Segmentebene als auch auf Session-Ebene, wobei verschiedene Leistungsmetriken wie F1-Score, ROC-Kurve, KISMED-Performancemetrik und Latenz berücksichtigt werden.

Auf Segmentebene zeigt sich, dass Wavelet-ANN den höchsten F1-Score erzielt, gefolgt von Wavelet-SVM und Time-CNN. Interessanterweise schneidet das Time-CNN jedoch bei der Analyse der Sessions am besten ab. Auch die Werte für die KISMED-Performancemetrik und die Latenz sprechen zugunsten von Time-CNN. Dies legt nahe, dass Time-CNN besser in der Lage ist, die gesamte Session zu analysieren und den Anfall zu detektieren, als auf Segmentebene.

Zukünftige Arbeiten sollten neben der Optimierung der Modelle auch die Vor- und Nachverarbeitung durch Filtern von Artefakten oder zusätzlicher Klassifizierungsmechanismen für Sessions verbessern. Darüber hinaus könnten Hyperparameter-Tuning und Feature-Selektion zur Optimierung der Modelle beitragen, obwohl dies mit einem höheren Ressourcenbedarf verbunden ist.

## LITERATUR

- [1] World Health Organization. *Epilepsie*. Zugegriffen: 19. Februar 2024. 2024. URL: <https://www.who.int/news-room/fact-sheets/detail/epilepsy>.
- [2] M. P. Kerr. "The impact of epilepsy on patients' lives". In: *Acta Neurologica Scandinavica* (2012). DOI: 10.1111/ane.12014.
- [3] Paul Yash. "Various epileptic seizure detection techniques using biomedical signals: a review". In: *Brain informatics* 5 (2018). DOI: 10.1186/s40708-018-0084-z.
- [4] G. Dorffner. *Basics 3: Die Wavelet-Transformation*. Zugegriffen: 22. Februar 2024. 2020. URL: <https://www.meduniwien.ac.at/user/georg.dorffner/lv/Biosig-Basics3.pdf>.
- [5] Yinxia Liu u. a. "Automatic Seizure Detection Using Wavelet Transform and SVM in Long-Term Intracranial EEG". In: *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 20.6 (2012), S. 749–755. DOI: 10.1109/TNSRE.2012.2206054.
- [6] Hamidreza Bakhshi Mehdi Omidvar Abdulhamid Zahedi. "EEG signal processing for epilepsy seizure detection using 5-level Db4 discrete wavelet transform, GA-based feature selection and ANN/SVM classifiers". In: *Journal of Ambient Intelligence and Humanized Computing* (2021). DOI: 10.1007/s12652-020-02837-8.
- [7] Rohan Akut. "Wavelet based deep learning approach for epilepsy detection". In: *Health information science and systems* 7 (2019). DOI: 10.1007/s13755-019-0069-1.
- [8] R. Panda u. a. "Classification of EEG signal using wavelet transform and support vector machine for epileptic seizure detection". In: *2010 International Conference on Systems in Medicine and Biology*. 2010, S. 405–408. DOI: 10.1109/ICSMB.2010.5735413.
- [9] Sara Mihandoost, Mehdi Chehel Amirani und Behrooz Zali Varghahan. "Seizure detection using wavelet transform and a new statistical feature". In: *2011 5th International Conference on Application of Information and Communication Technologies (AICT)*. 2011, S. 1–5. DOI: 10.1109/ICAICT.2011.6110942.
- [10] Bhanwala Harender und R. K. Sharma. "DWT based epileptic seizure detection from EEG signal using k-NN classifier". In: *2017 International Conference on Trends in Electronics and Informatics (ICEI)*. 2017, S. 762–765. DOI: 10.1109/ICOEI.2017.8300806.
- [11] P. Gnip, L. Vokorokos und P. Drotár. "Selective oversampling approach for strongly imbalanced data". In: *PeerJ Computer science* 7 (2021). DOI: 10.7717/peerj-cs.604.
- [12] J. Sola und Joaquin Sevilla. "Importance of input data normalization for the application of neural networks to complex industrial problems". In: *Nuclear Science, IEEE Transactions on* 44 (Juli 1997), S. 1464–1468. DOI: 10.1109/23.589532.
- [13] Sejal Jaiswal. *What is Normalization in Machine Learning? A Comprehensive Guide to Data Rescaling*. Zugegriffen: 22. Februar 2024. 2024. URL: <https://www.datacamp.com/tutorial/normalization-in-machine-learning>.
- [14] G. Wilhelm und A. Specht. *Identifikation von relevanten Metriken zur Analyse von Kommunikation in Entwicklungsteams*. 2021.
- [15] Nadia Mammone und Francesco C. Morabito. "Enhanced Automatic Wavelet Independent Component Analysis for Electroencephalographic Artifact Removal". In: *Entropy* 16 (). DOI: 10.3390/e16126553.

## ANHANG A

Der Flowchart der drei verwendeten Methoden ist in Abbildung A.1 dargestellt.

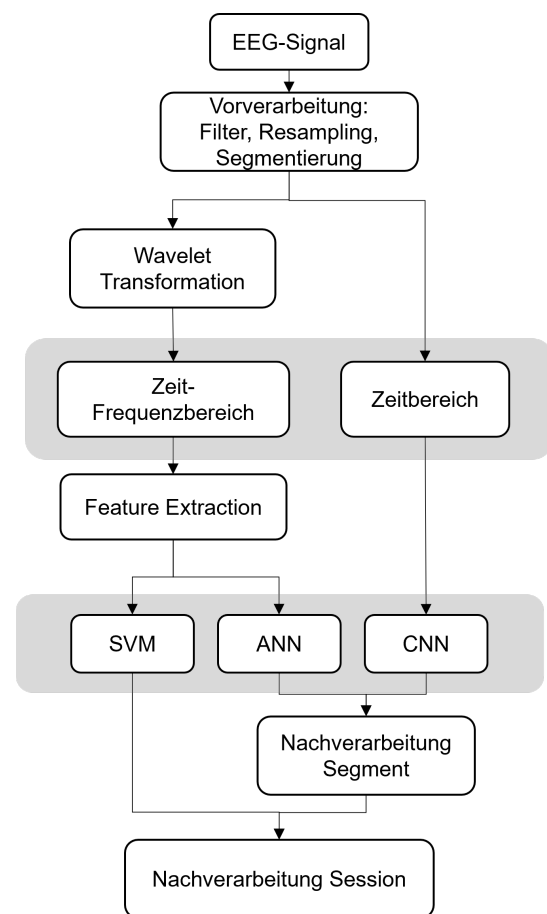


Abbildung A.1: Flowchart der Methoden

## ANHANG B

Die Wavelet Dekomposition mit der db4-Funktion ist für ein EEG-Signal beispielhaft in Abbildung B.1 dargestellt. Dabei ist deutlich zu erkennen, dass die zeitlichen Informationen bei der Transformation erhalten bleiben und das Signal nur in einzelne Frequenzbänder aufgeteilt wird.



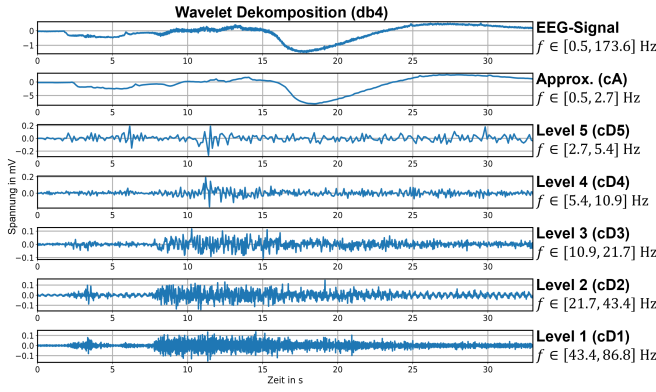


Abbildung B.1: Waveletdekomposition eines EEG Signals

## ANHANG C

Die Formeln zu Berechnung der Features aus den Koeffizienten lauten wie folgt

- Energie:

$$Energie = \sum_{i=1}^N X_i^2 \quad (C.1)$$

- Entropie:

$$Entropie = \sum_{i=1}^N X_i^2 \log(X_i^2) \quad (C.2)$$

- Mittelwert ( $\mu$ ):

$$\mu = \frac{1}{N} \sum_{i=1}^N X_i \quad (C.3)$$

- Standardabweichung (STD):

$$STD = \sqrt{\frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2} \quad (C.4)$$

- Nulldurchgangsrate (ZCR):

$$ZCR = \frac{\text{Anzahl der Peaks}}{\text{Anzahl der Datenpunkte}} \quad (C.5)$$

- Mean Absolute Value (MAV):

$$MAV = \frac{1}{N} \sum_{i=1}^N |X_i| \quad (C.6)$$

wobei  $X_i$  der einzelne Datenpunkt und N die gesamte Anzahl an Datenpunkten ist.

## ANHANG D

Das CNN (Abbildung D.1) wird mit einer Batch-Größe von 64 über einen Zeitraum von 250 Epochen trainiert. Um Overfitting zu vermeiden, wird ein vorzeitiges Beenden implementiert, das greift, wenn der Validierungsverlust über 40 Epochen hinweg keine Verbesserung zeigt. Jedes Segment wird mit einem Wahrscheinlichkeitswert versehen, der angibt, mit welcher Wahrscheinlichkeit das Segment einen Anfall

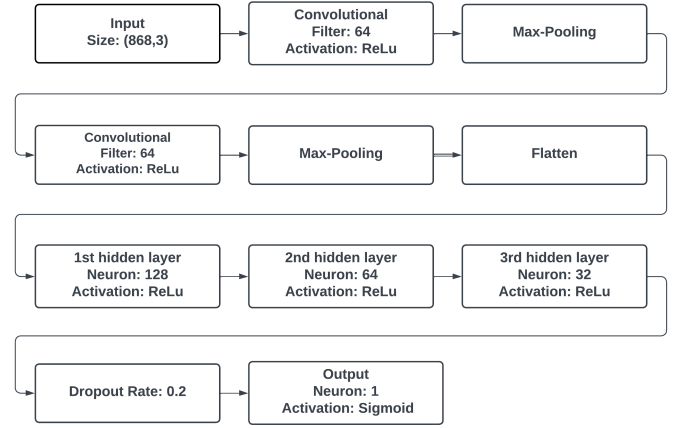


Abbildung D.1: Die Architektur des CNN-Modells

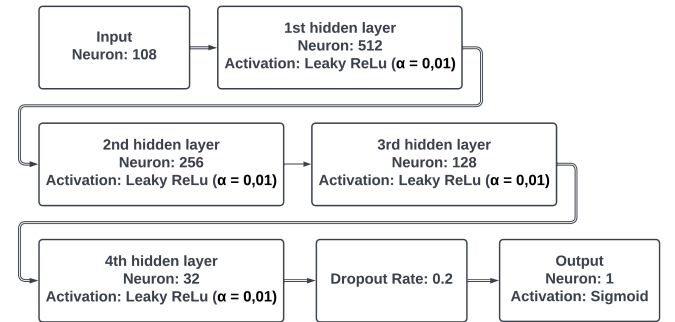


Abbildung D.2: Die Architektur des ANN-Modells

aufweist.

Das ANN (Abbildung D.2) wird mit einer Batch-Größe von 32 über 250 Epochen trainiert. Vorzeitiges Beenden tritt auf, wenn der Validierungsverlust über 50 Epochen hinweg keine Verbesserung zeigt.

Die drei SVM-Modelle verwenden RBF Kernel, Strafterm C=1000, automatische Berechnung des Gamma-Werts und Shrinking für eine beschleunigte Berechnung. Sagen zwei der drei Modelle einen Anfall voraus, so wird das Segment mit '1' (Anfall) klassifiziert.

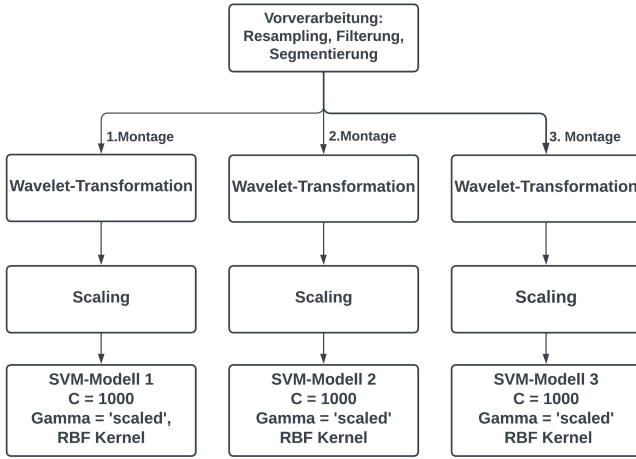


Abbildung D.3: Die Architektur des SVM-Modells

## ANHANG E

Für die Analyse der Sessions werden die Anzahlen der richtig positiven (True Positives, TP), richtig negativen (True Negatives, TN), falsch positiven (False Positives, FP) und falsch negativen (False Negatives, FN) Vorhersagen benötigt. Die Werte werden in dem hier vorliegenden Fall von der Latenz abhängig definiert. Ein TP liegt vor, wenn die zeitliche Differenz zwischen Vorhersage und Anfall kleiner als 30 Sekunden ist. Ein FN tritt auf, wenn ein Anfall nicht vorhergesagt wird, während ein FP auftritt, wenn kein Anfall vorliegt, aber eine Vorhersage gemacht wurde. Mit diesen Werten berechnen sich Accuracy, Recall und Precision zu

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (\text{E.1})$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (\text{E.2})$$

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (\text{E.3})$$

Mit den Werten kann nun auch der F1-Score berechnet werden.

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (\text{E.4})$$

Die Latenz berechnet sich mit

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N \min(|\text{Onset}_{\text{pred}_i} - \text{Onset}_{\text{gt}_i}|, 60\text{s}) \quad (\text{E.5})$$

Über die genaue Berechnung der Performance Metrik des KISMED Instituts liegen leider keine weiteren Informationen vor.